Практична робота 4. Дерево рішень і випадковий ліс

Мета. Навчити дерево рішень і випадковий ліс на реальних даних, порівняти їх, дослідити вплив гіперпараметрів, перевірити ключові формули вручну і пояснити роботу та основні поняття у відео.

Що потрібно. Ноутбук-заготовка pr4_template.ipynb і папка data поруч із ним (drybean.csv, occupancy.csv). У заготовці є лише код завантаження даних: він читає файл вашого варіанту і ділить дані на X_tr, y_tr (навчальна вибірка), X_va, y_va (валідаційна), X_te, y_te (тестова). Код усіх завдань пишете самі - під кожне завдання в ноутбуці є заголовок і порожня клітинка.

Що здати. Одразу після пари - посилання на GitHub-репозиторій з виконаним ноутбуком (завдання 1–7); протягом 2 днів після пари - відео-пояснення до 15 хвилин. Деталі - у розділах «Відео-пояснення» і «Що здати».

Варіант

Номер у списку групи	Варіант	Датасет	Задача
непарний	VARIANT = 'bean'	Dry Bean, 13 611 зерен	за 16 ознаками форми зерна визначити один із 7 сортів квасолі
парний	VARIANT = 'occupancy'	Occupancy Detection, 20 560 записів	за температурою, вологістю, освітленням і CO_2 визначити, чи є хтось у кімнаті

Варіант задається в першій клітинці ноутбука. Дані вже поділено на три частини: навчальна вибірка (train) - на ній модель вчиться; валідаційна вибірка (validation) - на ній обираємо параметри; тестова вибірка (test) - одна фінальна перевірка.

Терміни. Точність (accuracy) - частка правильних відповідей. Влучність (precision) - яка частка прогнозів «клас k» справді належить класу k. Повнота (recall) - яку частку об'єктів класу k модель знайшла. Далі в тексті використовуються українські назви, англійські - у дужках, як у коді.

Документація scikit-learn до цих метрик:

Точність (accuracy_score) - частка правильних відповідей

Влучність (precision_score) - параметри average, zero_division

Повнота (recall_score) - параметр average

Звіт по класах (classification_report) - влучність, повнота і f1 для кожного класу

Матриця помилок (confusion_matrix) - рядки - справжній клас, стовпці - прогноз

Завдання

Завдання 1. Знайомство з даними (0.5 бала)

Зробити:

(а) вкажіть свій варіант у VARIANT і запустіть першу клітинку; перегляньте дані (head(), describe());

(б) порахуйте, скільки прикладів кожного класу в навчальній вибірці (value_counts()), і побудуйте графік розподілу класів;

(в) порахуйте точність (accuracy) «лінивої» моделі, яка завжди відповідає найчастішим класом, на валідаційній вибірці (validation).

Результат у ноутбуці:

- кількість ознак і кількість класів;
- графік розподілу класів у навчальній вибірці (train);
- точність (accuracy) лінивої моделі на валідаційній вибірці (число);
- відповідь одним реченням: чи збалансовані класи.

Завдання 2. Дерево рішень (1 бал)

Зробити:

(а) навчіть DecisionTreeClassifier(max_depth=3, random_state=0) на навчальній вибірці (train);

(б) виведіть точність (accuracy) на навчальній (train) і валідаційній (validation) вибірках;

(в) намалюйте дерево (plot_tree) і виведіть його текстом (export_text).

Результат у ноутбуці:

- точність (accuracy) на навчальній і валідаційній вибірках (два числа);
- рисунок дерева;
- одне правило з дерева, записане словами: «якщо …, і …, то клас …»;
- відповідь: яке перше запитання поставило дерево.

Завдання 3. Випадковий ліс і порівняння (1 бал)

Зробити:

(а) навчіть RandomForestClassifier(n_estimators=100, random_state=0) на навчальній вибірці (train);

(б) для дерева і лісу порахуйте на валідаційній вибірці (validation) точність (accuracy), влучність (precision) і повноту (recall), усереднені по класах (average="macro");

(в) побудуйте матриці помилок (confusion matrix) обох моделей.

Результат у ноутбуці:

- таблиця або вивід: точність, влучність і повнота для дерева і для лісу;
- дві матриці помилок поруч;
- відповідь: яка модель краща і на скільки (за точністю); які два класи модель плутає найчастіше (для occupancy - яких помилок більше: пропущених людей чи хибних тривог).

Завдання 4. Експеримент з параметрами (1 бал)

Зробити:

(а) для дерева з max_depth від 1 до 20 порахуйте точність (accuracy) на навчальній (train) і валідаційній (validation) вибірках і побудуйте графік;

(б) для лісу з n_estimators = 1, 5, 10, 25, 50, 100, 200, 300 порахуйте точність (accuracy) на валідаційній вибірці (validation) і побудуйте графік;

(в) оберіть найкращу глибину дерева за валідаційною вибіркою (validation) і лише після цього один раз перевірте найкраще дерево і ліс на тестовій вибірці (test).

Результат у ноутбуці:

- графік «глибина дерева → точність» (навчальна і валідаційна вибірки);
- графік «кількість дерев → точність» (валідаційна вибірка);
- найкраща глибина і її точність на валідаційній вибірці;
- точність найкращого дерева і лісу на тестовій вибірці (два числа);
- відповіді: з якої глибини починається перенавчання; скільки дерев лісу достатньо.

Завдання 5. Важливість ознак (1 бал)

Зробити:

(а) побудуйте графік важливості ознак (feature_importances_) для дерева і лісу;

(б) визначте три найважливіші ознаки лісу;

(в) навчіть ще один ліс (100 дерев) зі зміненим набором ознак і порівняйте з повним: варіант bean - лише три найважливіші ознаки; варіант occupancy - усі ознаки, крім Light.

Результат у ноутбуці:

- графік важливості ознак;
- список трьох найважливіших ознак і пояснення, що кожна означає фізично;
- точність (accuracy) зміненої моделі на валідаційній і тестовій вибірках поруч із повною моделлю, дві матриці помилок;
- відповідь: що змінилося і чому.

Завдання 6. Нові випадки (0.5 бала)

Зробити:

(а) створіть щонайменше три власні вхідні приклади як pd.DataFrame з тими самими стовпцями, що й features (підказка: bean - візьміть медіани двох сортів, X_tr[y_tr == 'SIRA'].median(), і точки між ними; occupancy - задайте різні Light і CO2, решту - типові значення);

(б) отримайте прогнози найкращого дерева і лісу;

(в) виведіть ймовірності класів за лісом (predict_proba).

Результат у ноутбуці:

- таблиця: приклад - прогноз дерева - прогноз лісу - ймовірності лісу;
- щонайменше один приклад, де дерево і ліс відповідають по-різному;
- пояснення двома-трьома реченнями, чому моделі відповіли по-різному.

Завдання 7. Порахувати руками (1.5 бала)

Спочатку порахуйте самі - на папері (сфотографуйте і вставте фото в ноутбук) або в markdown-клітинці з усіма проміжними числами. Калькулятор можна, код - ні. Потім напишіть код, який рахує ті самі величини, і звірте.

Зробити:

(а) Індекс Джині кореня дерева. З рисунка дерева із завдання 2 випишіть samples і value для кореня та двох його дітей. Для кожного вузла порахуйте частки класів p_k = value_k / samples і індекс Джині:

$$G = 1 - \sum_k p_k^2$$

Потім - зважений Джині після поділу G′ (n, n_L, n_R - samples кореня, лівої і правої дитини) і його зменшення ΔG:

$$G' = \frac{n_L}{n} \cdot G_L + \frac{n_R}{n} \cdot G_R, \qquad \Delta G = G - G'$$

(б) Влучність (precision) і повнота (recall) одного класу. З матриці помилок лісу (завдання 3) для класу SIRA (bean) або класу 1 (occupancy) випишіть: скільки правильних (на діагоналі), скільки всього прогнозів цього класу (сума стовпця), скільки справжніх об'єктів цього класу (сума рядка). Порахуйте: влучність = правильні / сума стовпця, повнота = правильні / сума рядка.

(в) Бутстреп (bootstrap). Кожне дерево лісу вчиться на вибірці з n рядків, взятих з поверненням. Порахуйте ймовірність, що конкретний рядок навчальної вибірки жодного разу не потрапить у вибірку дерева, для вашого n:

$$P = \left(1 - \frac{1}{n}\right)^n$$

Результат у ноутбуці:

- ручні обчислення з проміжними числами для (а), (б), (в);
- код, який рахує ті самі величини (з tree_.value, tree_.n_node_samples, confusion_matrix), і його вивід;
- відповідь: чи збіглися числа; на скільки корінь зменшив «перемішаність» класів; яка частка навчальної вибірки не потрапляє в кожне дерево.

Відео-пояснення

Запишіть відео, у якому ви своїми словами пояснюєте свою роботу: дані, код, результати, висновки - і три теоретичні поняття за своїм номером. Мета - показати, що ви розумієте, що і навіщо робили, а не прочитати ноутбук уголос.

Вимоги до відео

- Тривалість - не більше 15 хвилин (рекомендовано 10–15).
- Запис екрана з вашим голосом; на екрані - ваш ноутбук із виконаними клітинками. Камера з обличчям - бажано (хоча б на початку).

- На початку назвіть свій варіант.
- Говорите самостійно, без читання з листка; голос синтезатора не приймається.
- Якість: текст і графіки на екрані читаються, голос чути без шуму.
- Формат - mp4 або посилання на відео (Google Drive / YouTube з доступом за посиланням); строк - 2 дні після пари.

Три поняття для пояснення

Кожен пояснює три поняття свого варіанту. Для кожного поняття дайте відповіді на питання з таблиці - своїми словами, з формулою і невеликим прикладом.

Варіант	**Поняття**	**На які питання відповісти у відео**
bean	функція втрат (loss function)	Що таке функція втрат і чому навчання моделі - це її мінімізація? Які функції втрат бувають для класифікації і для регресії (крос-ентропія, MSE)? Що «мінімізує» дерево рішень на кожному поділі і чим це відрізняється від мінімізації втрат у лінійній чи логістичній регресії? Приклад: порахуйте крос-ентропію для прогнозу 0.9 і 0.1 правильного класу - чому впевнена помилка «карається» сильніше?
bean	ентропія (entropy)	Що вимірює ентропія і яка її формула? Чому ентропія 0 у чистому вузлі і максимальна, коли класи рівні? Скільки це для 2 і для 7 класів? Чим ентропія схожа на індекс Джині і чим відрізняється? Як увімкнути її в дереві (criterion='entropy')? Приклад: ентропія кореня вашого дерева (частки класів з рисунка).
bean	приріст інформації (information gain)	Що таке приріст інформації і як його рахують (ентропія батька мінус зважена ентропія дітей)? Як дерево використовує його, щоб обрати ознаку і поріг? Чому на кожному кроці дерево

Варіант	Поняття	На які питання відповісти у відео
		обирає найкращий поділ «жадібно» і чим це погано? Приклад: приріст інформації першого поділу вашого дерева.
occupancy	середньоквадратична помилка (MSE)	Що таке MSE, яка формула і в яких одиницях вона вимірюється? Чим MSE відрізняється від MAE і RMSE? Чому MSE - метрика регресії, а не класифікації? Яку регресійну задачу можна поставити на ваших даних (наприклад, прогнозувати CO2)? Як регресійне дерево (DecisionTreeRegressor) використовує MSE для вибору поділу і що прогнозує листок? Приклад: MSE для 3–4 чисел вручну.
occupancy	коефіцієнт детермінації (R^2)	Що показує R^2 і яка формула? Чому $R^2 = 1$ - ідеально, 0 - як прогноз «завжди середнє», а < 0 - гірше? Чим R^2 зручніший за MSE для порівняння моделей? Що повертає score() у регресійного дерева і лісу (на відміну від класифікатора)? Приклад: R^2 для тих самих 3–4 чисел.
occupancy	перенавчання (overfitting)	Що таке перенавчання і як його видно на графіку «глибина → точність» (train vs validation)? Чому глибоке дерево перенавчається, а ліс - менше? Які параметри з цим борються (max_depth, min_samples_leaf, n_estimators)? Чим перенавчання відрізняється від зсуву даних (інший тиждень у test, ліс без Light у завданні 5)? Приклад: на вашому графіку покажіть, з якої глибини почалося перенавчання.

Де почитати про кожне поняття - у Додатку Б, документація бібліотек - у Додатку Г; розібратися глибше потрібно самостійно.

Структура відео

Частина	Орієнтовно	Що показати і пояснити
1. Дані	1–2 хв	що описує датасет, які ознаки і ціль, скільки класів, чи збалансовані навіщо навчальна, валідаційна і тестова вибірки
2. Суть моделей	2 хв	у чому суть дерева рішень і як воно приймає рішення (пройти один шлях від кореня до листка) у чому суть випадкового лісу і чим він відрізняється від дерева
3. Ручні обчислення	2 хв	свої обчислення Джині кореня, влучності й повноти класу, бутстрепу звірка з кодом
4. Порівняння і експеримент	2 хв	точність, влучність, повнота і матриці помилок графіки глибини і кількості дерев де перенавчання чому тестова вибірка використана лише один раз
5. Ознаки і нові випадки	2 хв	найважливіші ознаки і їхній фізичний зміст що змінилося без них приклад, де дерево і ліс розійшлися
6. Три поняття	4–5 хв	три поняття свого варіанту - відповіді на питання з таблиці «Три поняття для пояснення»
7. Висновки	1 хв	три головні висновки своїми словами

Пояснюючи код, не читайте кожен рядок: покажіть ключові рядки (fit, predict, параметри моделі, вибір найкращої глибини) і скажіть, що вони роблять і чому саме так.

Що здати

Одразу після пари - посилання на GitHub.

- Створіть репозиторій pr4-random-forest (публічний) і завантажте в нього ноутбук Прізвище_pr4.ipynb з усіма виконаними клітинками, графіками і клітинкою «Висновки» (сім коротких відповідей, по одній на кожне завдання).
- У ноутбуці або окремим файлом у репозиторії - фото чи markdown-клітинка з ручними обчисленнями (завдання 7).

- Додайте короткий README.md: прізвище, група, варіант, що зроблено.
- Папку data завантажувати не обов'язково.
- Надішліть посилання на репозиторій викладачу до кінця дня пари. Коміти після цього строку не враховуються.

Протягом 2 днів після пари - відео.

- Надішліть посилання на відео (Google Drive / YouTube з доступом за посиланням) або файл Прізвище_pr4.mp4.
- Посилання на відео також додайте в README.md репозиторію.

Оцінювання

Частина	Балів	Що перевіряється
1. Дані	0.5	графік класів, лінива модель
2. Дерево	1	точність, рисунок дерева, правило словами
3. Ліс	1	точність, влучність, повнота обох моделей, матриці помилок, висновок
4. Експеримент	1	два графіки, вибір глибини на валідаційній вибірці, тестова - один раз
5. Важливість ознак	1	графік, топ-3 з поясненням, порівняння моделей
6. Нові випадки	0.5	свої приклади, розбіжність моделей, пояснення
7. Ручні обчислення	1.5	Джині кореня і дітей, влучність / повнота, бутстреп проміжні числа збіг з кодом
Відео	3.5	усі частини структури (1.5) три поняття свого набору - що, для чого, зв'язок з моделлю, приклад (1.5) пояснення своїми словами, тривалість і вимоги (0.5)
Разом	10	

Бал знижується, якщо немає відповіді на питання завдання, якщо параметри обрано за тестовою вибіркою замість валідаційної, якщо ручні обчислення подано без проміжних кроків або якщо у відео ноутбук просто зачитується. Без відео робота оцінюється максимум у 6.5 бала.

Додаток А. Дані

Варіант bean: Dry Bean

13 611 зерен семи сортів квасолі сфотографовано камерою; з кожного фото обчислено 16 ознак форми. Це прообраз автоматичної лінії сортування: камера над конвеєром, модель за формою зерна

вирішує, у який бункер його скинути. Джерело: UCI Machine Learning Repository, Dry Bean Dataset (Koklu, Ozkan, 2020). Поділ: 60 % train (8164), 20 % validation (2721), 20 % test (2726) з однаковими пропорціями сортів.

Ознака	**Що означає**
Area, Perimeter	площа (у пікселях) і периметр зерна на фото
MajorAxisLength, MinorAxisLength	довжина і ширина зерна
AspectRatio, Eccentricity	наскільки зерно видовжене
ConvexArea, Solidity	площа опуклої оболонки і частка, яку займає зерно
EquivDiameter	діаметр кола з тією самою площею
Extent	частка площі зерна в описаному прямокутнику
Roundness, Compactness	наскільки зерно кругле
ShapeFactor1–4	додаткові безрозмірні коефіцієнти форми
Class	сорт: SEKER, BARBUNYA, BOMBAY, CALI, HOROZ, SIRA, DERMASON

Варіант occupancy: Occupancy Detection

Офісна кімната; датчики раз на хвилину записують температуру, вологість, освітленість і CO_2, а камера фіксувала, чи є хтось у кімнаті. Мета - виявляти присутність без камери. Джерело: UCI Machine Learning Repository, Occupancy Detection (Candanedo, Feldheim, 2016). Поділ за часом: train - 4–10 лютого 2015 (8143 записи), validation - 2–4 лютого (2665), test - 11–18 лютого (9752): модель перевіряємо на інших днях, ніж ті, на яких вона вчилася.

Стовпець	**Що означає**
date	дата і час виміру
Temperature	температура, °C
Humidity	відносна вологість, %
Light	освітленість, люкс
CO2	концентрація CO_2, ppm
HumidityRatio	абсолютна вологість, кг водяної пари на кг повітря
Occupancy	ціль: 1 - хтось є, 0 - порожньо

Додаток Б. Де почитати

Означення понять тут не наведено - знайдіть і розберіть їх самостійно за посиланнями.

Моделі

Дерево рішень - посібник scikit-learn

Індекс Джині, ентропія, MSE як критерії поділу - формули критеріїв

Випадковий ліс - посібник scikit-learn

Беггінг (bagging) - посібник scikit-learn

Бутстреп (bootstrap) - Wikipedia

Важливість ознак (feature importance) - посібник scikit-learn

Метрики

Точність (accuracy) - посібник scikit-learn

Влучність (precision) і повнота (recall) - посібник scikit-learn

Матриця помилок (confusion matrix) - посібник scikit-learn

Поняття для відео

Функція втрат (loss function) - Wikipedia

Ентропія (entropy) - Wikipedia

Приріст інформації (information gain) - Wikipedia

Середньоквадратична помилка (MSE) - посібник scikit-learn

Коефіцієнт детермінації (R^2) - посібник scikit-learn

Перенавчання (overfitting) - приклад scikit-learn з графіками

Додаток В. Додаткові завдання (за бажанням)

- Обмежте глибину дерев лісу (max_depth=5, 10) або задайте min_samples_leaf=5. Як змінилися train і validation?
- Варіант bean: додайте class_weight='balanced'. Чи покращився recall для сортів BOMBAY і SIRA?
- Варіант occupancy: додайте ознаку «година доби» (pd.to_datetime(df['date']).dt.hour) і повторіть завдання 5 без Light. Чи допомогло?

Додаток Г. Документація

Офіційна документація бібліотек, які використовуються в роботі. Якщо незрозуміло, що робить функція або параметр, - шукайте спершу тут.

Датасети

Dry Bean Dataset (UCI) - варіант bean: опис ознак, стаття авторів, оригінальні файли

Occupancy Detection (UCI) - варіант occupancy: опис датчиків, стаття авторів, оригінальні файли

Python і бібліотеки

Python 3 - мова, стандартна бібліотека, підручник (Tutorial)

NumPy - масиви й обчислення (np.argmax, np.unique, random.default_rng)

pandas - таблиці: read_csv, DataFrame, value_counts, describe

Matplotlib - графіки: plot, bar, subplots

Jupyter - робота з ноутбуками, markdown-клітинки

scikit-learn

Посібник: дерева рішень - як будується дерево, критерій Джині, перенавчання

Посібник: ансамблі (випадковий ліс) - бутстреп, випадкові ознаки, важливість ознак

DecisionTreeClassifier - параметри max_depth, min_samples_leaf, criterion

RandomForestClassifier - параметри n_estimators, max_features, n_jobs

plot_tree - малювання дерева

Метрики класифікації - accuracy, precision, recall, матриця помилок

Точність (accuracy_score) - частка правильних відповідей

Влучність (precision_score) - параметри average, zero_division

Повнота (recall_score) - параметр average

Звіт по класах (classification_report) - влучність, повнота і f1 для кожного класу

Матриця помилок (confusion_matrix) - рядки - справжній клас, стовпці - прогноз

Метрики регресії - MSE, R^2 та інші - для понять у відео

Критерії поділу дерева - Джині, ентропія, MSE - формули

ConfusionMatrixDisplay - малювання матриці помилок